UNIVERSIDAD TECNOLÓGICA NACIONAL

FACULTAD REGIONAL BUENOS AIRES

DIPLOMATURA EN DATA SCIENCE Y ANALÍTICA DE DATOS

PROYECTO INTEGRADOR FINAL — ENTREGA

Segmentación de Clientes RFM y Sistema de Recomendación Personalizado en Comercio Electrónico

Autora: Angela Cardozo

Especialidad: Marketing Dirección y Estrategia

Tutor / Profesor: Francisco Portas

Fecha de Entrega: 30 de octubre de 2026

Indice

1. Resumen ejecutivo 1
2. Datos y Metodología 2
   2.1 Fuente y calidad de los datos 2
   2.2 Análisis exploratorio 2
   2.3 Separación temporal y prevención de fuga de información 2
   2.4 Enfoque CRISP-DM 3
3. Modelado y Evaluación comparativa 3
   3.1 Tabla 1 Resultados de Validación de los modelos de Recomendación 4
   3.2 Justificacion de la selección 5
4. Segmentación RFM y Estrategias de Negocio 5
   Resultados de la segmentación 6
   Interpretación de los resultados 7
   Justificación de la selección de cuatro clústeres 7
   Justificación del modelo Usuario-Usuario y las estrategias por segmento 8
5. Impacto económico, Riesgos y Consideraciones éticas 8
   5.1. Impacto potencial en el negocio 8
   5.2. Estimación del beneficio económico 9
   5.3. Riesgos y limitaciones 10
   5.4. Consideraciones éticas y privacidad 10
   5.5. Validación comercial futura 11
6. Conclusiones y recomendaciones 11
   6.1. Conclusiones generales 11
   6.2. Resultados del sistema de recomendación 12
   6.3. Aportes de la segmentación RFM 12
   6.4. Recomendaciones y próximos pasos 13
   6.5. Conclusión final 13

7. Referencias y recomendaciones 14

1. Resumen ejecutivo

El presente proyecto analiza transacciones de comercio electrónico del conjunto de datos Online Retail, con el propósito de integrar técnicas de segmentación de clientes mediante Recency, Frequency y Monetary (RFM) con sistemas de recomendación de productos. Se compararon tres enfoques: productos más vendidos (Top-Sellers), filtrado colaborativo Usuario-Usuario y filtrado colaborativo Ítem-Ítem.

El trabajo se desarrolló siguiendo la metodología CRISP-DM y una división temporal de los datos en entrenamiento, validación y prueba, con el objetivo de evitar la utilización de información futura durante el desarrollo y evaluación de los modelos.

A partir de 541.909 registros originales, se obtuvieron 397.884 transacciones positivas válidas, correspondientes a 4.338 clientes y 3.665 productos.

En la etapa de validación, el modelo Usuario-Usuario obtuvo el mejor resultado de Precision@5 (0,049869), superando a Ítem-Ítem (0,044464) y Top-Sellers (0,034176). Por este motivo, fue seleccionado como modelo principal. Posteriormente, en el conjunto independiente de prueba, mantuvo su ventaja, alcanzando una Precision@5 de 0,051536 y un HitRate@5 de 0,187402.

Adicionalmente, se identificaron cuatro segmentos de clientes mediante RFM y K-Means: VIP/Alto valor, Leales/Frecuentes, Nuevos/Prometedores y En riesgo/Inactivos. Aunque la alternativa de dos grupos presentó un índice Silhouette superior, se seleccionaron cuatro segmentos por su mayor interpretabilidad y utilidad para formular estrategias comerciales diferenciadas.

Los resultados permiten identificar oportunidades para desarrollar recomendaciones personalizadas y propuestas comerciales orientadas a la fidelización, venta cruzada y reactivación de clientes. Sin embargo, las estrategias específicas por segmento constituyen propuestas de negocio cuya efectividad todavía debe comprobarse mediante pruebas comerciales controladas.

En conclusión, el proyecto demuestra la viabilidad técnica de combinar segmentación RFM y sistemas de recomendación para apoyar decisiones comerciales basadas en datos, aunque el desempeño predictivo y su impacto económico presentan oportunidades de mejora y requieren validación adicional.

2. Datos y Metodología

2.1 Fuente y calidad de los datos

Se utilizó Online Retail, con ocho columnas originales: InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID y Country. Se identificaron 135.080 registros sin CustomerID (24,93 %), 1.454 descripciones faltantes, 5.268 filas exactamente duplicadas, 10.624 devoluciones o cancelaciones indicativas y 2.517 precios no positivos. Los duplicados se identificaron, pero no se eliminaron automáticamente, ya que una coincidencia exacta puede corresponder a operaciones registradas legítimamente.

Las fechas se interpretaron con un formato explícito de mes/día/año y hora:minuto. Se eliminaron registros sin identificadores o variables indispensables, con cantidades o precios no positivos y facturas marcadas como canceladas. Se calculó TotalPrice = Quantity × UnitPrice. El período observado va del 1 de diciembre de 2010 al 9 de diciembre de 2011; el último mes está incompleto.

2.2 Análisis exploratorio

El análisis exploratorio incluyó evolución de ingresos mensuales, distribución de cantidades, precios e importes, y productos líderes por unidades vendidas. La suma de TotalPrice en el conjunto depurado fue aproximadamente 8.911.407,9 unidades monetarias del dataset. La serie muestra incrementos hacia septiembre-noviembre de 2011; la caída de diciembre no debe interpretarse como descenso mensual comparable porque el archivo finaliza el día 9.

2.3 Separación temporal y prevención de fuga de información

El conjunto se dividió cronológicamente en entrenamiento (181.242 filas), validación (55.116) y test (161.526). Los últimos 90 días se reservaron para test y los 60 días anteriores para validación. Los modelos y la segmentación de validación se construyeron con información anterior al período evaluado; tras elegir una estrategia, el procedimiento previsto consiste en

reentrenar con toda la historia anterior a test y evaluar sobre compras posteriores. Este diseño reduce la fuga temporal de información. La segmentación RFM se construyó utilizando exclusivamente las transacciones disponibles antes del período de evaluación correspondiente. De esta manera, tanto las variables de segmentación como los modelos de recomendación respetaron la secuencia temporal, evitando incorporar información futura en el proceso de entrenamiento y validación.

2.4 Enfoque CRISP-DM

Se aplicaron las fases de comprensión del negocio, comprensión y preparación de datos, modelado, evaluación y propuesta de despliegue. El despliegue operativo no se ejecutó: se presenta como una etapa futura sujeta a experimentación A/B, monitoreo y revisión de privacidad.

3. Modelado y Evaluación comparativa

Se desarrollaron y evaluaron tres enfoques de recomendación de productos utilizando el conjunto de datos Online Retail. Para garantizar una comparación metodológicamente consistente, se realizó una partición temporal de los datos en entrenamiento, validación y prueba, evitando utilizar información futura durante el entrenamiento de los modelos.

Modelos implementados

1. **Baseline Top-Sellers:** recomienda los cinco productos con mayor volumen de ventas históricas, excluyendo aquellos que el cliente ya adquirió.
2. **Filtrado Colaborativo Usuario-Usuario:** utiliza la similitud del coseno entre los patrones de compra de diferentes clientes para identificar productos potencialmente relevantes.
3. **Filtrado Colaborativo Ítem-Ítem:** calcula la similitud entre productos a partir de los patrones históricos de compra, con el objetivo de recomendar artículos relacionados.

Evaluación de los Modelos

Se utilizaron las métricas Precision@5, Recall@5, HitRate@5 y cobertura de usuarios. La selección del modelo se realizó exclusivamente con los resultados de validación, priorizando Precision@5 y utilizando Recall@5 como criterio de desempate.

3.1 Tabla 1 Resultados de Validación de los modelos de Recomendación

Modelado Algorítmico	Precision@5	Recall@5	HitRate@5
Top-Sellers	0,0342	0,0053	0,1569
Usuario-Usuario	**0,0499**	**0,0111**	**0.1805**
Ítem-Ítem	0,0445	0,0086	0.1674

Evaluación final en el conjunto de prueba

Una vez seleccionado el modelo Usuario-Usuario a partir de los resultados obtenidos en la etapa de validación, se realizó una evaluación independiente sobre el conjunto de prueba temporal. El modelo alcanzó una Precision@5 de 0,051536, un Recall@5 de 0,007778 y un HitRate@5 de 0,187402, superando a las estrategias Top-Sellers e Ítem-Ítem en las tres métricas globales.

Estos resultados respaldan la selección del filtrado colaborativo Usuario-Usuario como estrategia principal del proyecto. Sin embargo, el análisis por segmentos RFM muestra diferencias de desempeño entre los distintos perfiles de clientes, por lo que su superioridad global no implica necesariamente un mejor resultado en todos los segmentos.

Asimismo, los valores absolutos de precisión y recuperación evidencian oportunidades de mejora en la capacidad predictiva del sistema, especialmente en la identificación de productos relevantes para cada usuario.

Tabla 2 Resultados del Conjunto de prueba

Modelado Algorítmico	Precision@5	Recall@5	HitRate@5	Cobertura de usuarios
Top-Sellers	0,0375	0,0052	0,1624	100%
Usuario-Usuario	**0,0515**	**0,0078**	**0.1874**	**100%**
Ítem-Ítem	0,0438	0,0065	0.1666	100%

3.2 Justificacion de la selección

El modelo de filtrado colaborativo Usuario-Usuario presentó el mejor desempeño global en validación y mantuvo su ventaja en el conjunto de prueba.

En particular, alcanzó una Precision@5 de aproximadamente 5,15 % y un HitRate@5 de 18,74 % en la evaluación final, superando a los enfoques Top-Sellers e Ítem-Ítem.

Estos resultados respaldan la selección del modelo Usuario-Usuario como estrategia principal para la personalización de recomendaciones, aunque muestran oportunidades de mejora en la precisión y recuperación de productos relevantes

4. Segmentación RFM y Estrategias de Negocio

Se implementó un modelo de segmentación de clientes mediante la metodología RFM (Recency, Frequency, Monetary), utilizando el algoritmo K-Means con cuatro grupos.

Las variables consideradas fueron:

- **Recency:** cantidad de días transcurridos desde la última compra del cliente.
- **Frequency:** cantidad de facturas únicas registradas.
- **Monetary:** valor monetario acumulado de las compras.

Para el entrenamiento se aplicó una transformación logarítmica y una estandarización de las variables RFM. La segmentación se realizó utilizando exclusivamente información histórica anterior a cada período de evaluación, con el objetivo de evitar fugas de información futura.

Resultados de la segmentación

En el período de prueba se identificaron cuatro segmentos comerciales diferenciados.

Tabla 3. Características de los segmentos RFM

Segmento	Clientes	Recencia Mediana (días)	Frecuencia Mediana	Gasto Mediano
VIP/ alto valor	478	10,86	9	3.234,41
Leales/ Frecuentes	982	68,03	3	1.070,12
Nuevos/ prometedores	481	15,12	2	541,51
En riesgo/ Inactivos	1.429	155,22	1	251,02

Segmento VIP / Alto valor: clientes con elevada frecuencia de compra, alto gasto acumulado y actividad reciente. Se propone implementar recomendaciones personalizadas mediante filtrado colaborativo Ítem-Ítem para favorecer la venta cruzada, complementadas con beneficios exclusivos y programas de fidelización.

Segmento Leales / Frecuentes: clientes con compras recurrentes y un gasto intermedio-alto. Se recomienda utilizar filtrado colaborativo Usuario-Usuario para identificar productos relevantes a partir de los patrones de compra de clientes similares, promoviendo la recurrencia y fidelización.

Segmento Nuevos / Prometedores: clientes con compras recientes, pero con menor frecuencia e importe acumulado. Se propone combinar recomendaciones basadas en popularidad con estrategias de personalización progresiva, a medida que se disponga de mayor información sobre sus preferencias.

Segmento En riesgo / Inactivos: clientes con períodos prolongados sin compras y bajo gasto acumulado. Se propone implementar campañas de reactivación mediante productos

populares, comunicaciones segmentadas e incentivos comerciales, sujetos a una evaluación posterior de su efectividad.

Interpretación de los resultados

La segmentación permite identificar diferencias relevantes en el comportamiento de compra de los clientes.

El grupo VIP presenta el mayor gasto y frecuencia mediana, mientras que el segmento En riesgo / Inactivos concentra la mayor cantidad de clientes y registra los períodos más prolongados sin actividad.

Estos resultados permiten diseñar estrategias comerciales diferenciadas, orientadas a la fidelización, el incremento de la recurrencia y la recuperación de clientes inactivos.

Las estrategias propuestas constituyen recomendaciones de negocio derivadas del análisis y no resultados de campañas comerciales implementadas.

Justificación de la selección de cuatro clústeres

Se evaluaron dos alternativas de segmentación mediante el índice Silhouette: K = 2, con un resultado de 0,4337, y K = 4, con un resultado de 0,3597.

Aunque K = 2 presentó una mayor separación estadística entre los grupos, se seleccionó K = 4 por criterios de interpretabilidad y utilidad comercial. Esta configuración permitió identificar cuatro perfiles diferenciados de clientes: VIP / Alto valor, Leales / Frecuentes, Nuevos / Prometedores y En riesgo / Inactivos.

La elección responde al objetivo del proyecto de vincular la segmentación de clientes con estrategias de recomendación y acciones comerciales específicas. Por lo tanto, se priorizó la capacidad de generar segmentos accionables para el negocio, reconociendo que K = 4 no obtuvo el mayor índice Silhouette entre las alternativas evaluadas.

Justificación del modelo Usuario-Usuario y las estrategias por segmento

Relación entre el modelo seleccionado y las estrategias comerciales

El modelo de filtrado colaborativo Usuario-Usuario fue seleccionado como estrategia principal de recomendación a partir de los resultados obtenidos en el conjunto de validación, donde alcanzó el mejor desempeño en Precision@5 entre los tres enfoques evaluados.

Sin embargo, la segmentación RFM permitió identificar comportamientos de compra diferenciados, por lo que se plantearon estrategias comerciales específicas para cada grupo de clientes. Estas estrategias incluyen la utilización de recomendaciones personalizadas, productos populares y campañas de reactivación, según las características de cada segmento.

Es importante señalar que estas propuestas representan aplicaciones comerciales derivadas del análisis exploratorio y de la segmentación RFM. No constituyen evidencia de que un modelo de recomendación específico sea necesariamente superior para cada segmento. Su efectividad deberá comprobarse mediante evaluaciones adicionales y pruebas A/B en un entorno comercial real.

5. Impacto económico, Riesgos y Consideraciones éticas

5.1. Impacto potencial en el negocio

El proyecto propone mejorar la personalización de las recomendaciones de productos mediante la combinación de segmentación RFM y filtrado colaborativo, con el objetivo de fortalecer la fidelización, promover la recurrencia de compra y detectar oportunidades de venta cruzada.

Los resultados obtenidos permiten identificar al modelo Usuario-Usuario como la alternativa de mejor desempeño predictivo entre los enfoques evaluados.

En el conjunto de prueba, este modelo alcanzó una Precision@5 de 5,15 % y un HitRate@5 de 18,74 %, superando a la estrategia Top-Sellers.

Desde una perspectiva comercial, estos resultados respaldan la posibilidad de desarrollar campañas de marketing más personalizadas. Sin embargo, las métricas predictivas no permiten afirmar directamente que exista un incremento equivalente en las ventas.

5.2. Estimación del beneficio económico

Para evaluar el potencial económico del proyecto, se plantea un escenario hipotético de implementación de una campaña de recomendaciones personalizadas.

Se consideran los siguientes supuestos:

Variable	**Valor estimado**
Clientes alcanzados	10.000
Tasa de conversión incremental hipotética	3%
Ticket promedio supuesto	USD 55
Margen de contribución supuesto	30%

Bajo estas condiciones, se estima:

- Compras adicionales: 10.000 × 3 % = 300.
- Ingresos incrementales: 300 × USD 55 = USD 16.500.
- Contribución incremental antes de costos de campaña: USD 16.500 × 30 % = USD 4.950.

Este cálculo constituye una simulación ilustrativa basada en supuestos comerciales y no representa un beneficio económico observado en el dataset.

Para determinar el retorno real de la inversión sería necesario incorporar los costos de implementación, mantenimiento y ejecución de campañas, así como medir el efecto incremental mediante una prueba A/B.

5.3. Riesgos y limitaciones

El proyecto presenta las siguientes limitaciones:

Historial insuficiente: los clientes nuevos o con pocas compras pueden generar recomendaciones menos confiables debido a la falta de información sobre sus preferencias.

Datos históricos: el dataset Online Retail corresponde a un período limitado, por lo que sus patrones comerciales podrían no representar las condiciones actuales de un comercio electrónico.

Ausencia de variables comerciales adicionales: el sistema no incorpora disponibilidad de inventario, márgenes de rentabilidad, promociones ni información contextual que podría influir en las recomendaciones.

Limitaciones predictivas: las métricas obtenidas muestran un desempeño moderado, lo que indica oportunidades para mejorar los algoritmos y ampliar las variables utilizadas.

Escalabilidad: el cálculo de similitudes entre usuarios y productos puede incrementar los requerimientos de memoria y procesamiento a medida que aumenta el volumen de información.

5.4. Consideraciones éticas y privacidad

El tratamiento de los datos debe respetar principios de confidencialidad, minimización de información y utilización responsable de los registros de clientes.

Para una implementación comercial se recomienda utilizar identificadores seudonimizados, restringir el acceso a los historiales individuales y establecer políticas de conservación y eliminación de datos.

Asimismo, las recomendaciones deben evitar prácticas discriminatorias o la utilización de información personal que no resulte necesaria para el objetivo comercial.

En una implementación real en Argentina, el tratamiento de datos personales deberá adecuarse a la Ley 25.326 de Protección de Datos Personales y demás disposiciones aplicables.

5.5. Validación comercial futura

Como siguiente etapa, se propone desarrollar una prueba A/B que permita comparar dos grupos de clientes:

- **Grupo de control:** recibe recomendaciones tradicionales basadas en productos populares.
- **Grupo experimental:** recibe recomendaciones personalizadas mediante el modelo Usuario-Usuario.

Las métricas comerciales sugeridas son la tasa de conversión, el ticket promedio, los ingresos incrementales y el margen de contribución.

Esta evaluación permitiría determinar si la mejora observada en las métricas predictivas se traduce efectivamente en beneficios económicos para la empresa.

6. Conclusiones y recomendaciones

6.1. Conclusiones generales

El proyecto permitió desarrollar una propuesta de personalización comercial para un entorno de comercio electrónico mediante la integración de segmentación RFM y sistemas de recomendación de productos.

A partir del dataset Online Retail, compuesto originalmente por 541.909 registros, se realizó un proceso de limpieza que permitió obtener 397.884 transacciones válidas, correspondientes a 4.338 clientes únicos.

El análisis se desarrolló siguiendo la metodología CRISP-DM, integrando la comprensión del problema comercial, la preparación de datos, el modelado, la evaluación y la interpretación de resultados.

Para garantizar la validez metodológica, se implementó una división cronológica de los datos en entrenamiento, validación y prueba. Esta separación permitió construir los modelos utilizando información histórica y evaluar su capacidad de generar recomendaciones sobre compras posteriores, evitando la fuga de información identificada durante la revisión inicial del proyecto.

6.2. Resultados del sistema de recomendación

Se compararon tres estrategias: Top-Sellers, filtrado colaborativo Usuario-Usuario y filtrado colaborativo Ítem-Ítem.

El modelo Usuario-Usuario obtuvo el mejor desempeño en validación, alcanzando una Precision@5 de 4,99 %, por lo que fue seleccionado para la evaluación final.

En el conjunto de prueba mantuvo su ventaja, con una Precision@5 de 5,15 % y un HitRate@5 de 18,74 %.

Estos resultados indican que el modelo personalizado logró identificar productos posteriormente adquiridos por los clientes con mayor frecuencia que las estrategias alternativas evaluadas.

Sin embargo, el nivel de precisión obtenido evidencia que todavía existen oportunidades de mejora. Asimismo, una mayor coincidencia entre recomendaciones y compras históricas no demuestra por sí sola un incremento de las ventas.

6.3. Aportes de la segmentación RFM

La aplicación de K-Means permitió identificar cuatro perfiles comerciales: VIP / Alto valor, Leales / Frecuentes, Nuevos / Prometedores y En riesgo / Inactivos.

Aunque la configuración de dos clústeres presentó un índice Silhouette superior, se seleccionaron cuatro grupos por su mayor capacidad de diferenciación comercial.

Esta segmentación permitió identificar diferencias en recencia, frecuencia y gasto acumulado, proporcionando información relevante para diseñar acciones de fidelización, venta cruzada, captación de compras recurrentes y reactivación.

La combinación de segmentación RFM y recomendaciones personalizadas constituye una propuesta para orientar las acciones comerciales según el comportamiento histórico de cada grupo de clientes.

6.4. Recomendaciones y próximos pasos

A partir de los resultados obtenidos, se recomienda:

1. **Priorizar el modelo Usuario-Usuario** como alternativa inicial para futuras pruebas comerciales, dado que obtuvo el mejor desempeño predictivo en validación y prueba.
2. **Implementar estrategias diferenciadas por segmento RFM**, considerando el valor económico, la frecuencia de compra y la actividad reciente de los clientes.
3. **Profundizar la evaluación por segmento**, con el objetivo de determinar si los distintos modelos de recomendación presentan diferencias relevantes entre perfiles comerciales.
4. **Incorporar variables adicionales**, como disponibilidad de stock, categorías de productos, márgenes comerciales y comportamiento de navegación, para mejorar la relevancia de las recomendaciones.
5. **Desarrollar una prueba A/B**, comparando las recomendaciones personalizadas con una estrategia tradicional basada en popularidad, para medir su impacto real sobre la conversión, los ingresos y la rentabilidad.
6. **Monitorear periódicamente el desempeño del sistema**, actualizando los modelos con nuevos registros de compra y evaluando posibles cambios en los patrones de consumo.

6.5. Conclusión final

Los resultados obtenidos muestran que la aplicación conjunta de técnicas de segmentación y recomendación puede aportar información útil para mejorar la toma de decisiones comerciales en empresas de comercio electrónico.

El proyecto permitió identificar perfiles de clientes diferenciados y seleccionar, mediante una evaluación temporal, un modelo de recomendación que superó a las alternativas comparadas.

Si bien el desempeño predictivo presenta limitaciones y el impacto económico todavía requiere validación experimental, la propuesta constituye una base técnica para desarrollar

estrategias de marketing más personalizadas, medibles y orientadas al comportamiento de los clientes.

7. Referencias y recomendaciones

Fuente de datos: Online Retail, disponible en el repositorio público utilizado por el notebook: https://raw.githubusercontent.com/guipsamora/pandas_exercises/master/07_Visualization/Online_Retail/Online_Retail.csv

Herramientas: Python, pandas, NumPy, scikit-learn, SciPy y Matplotlib. Semilla de reproducibilidad observada: 42. El notebook contiene el procesamiento, la segmentación, los modelos y las evaluaciones. Las cifras reportadas corresponden a las salidas visibles en las capturas suministradas.

Nota para la entrega: incorporar las métricas finales de test desde la ejecución original antes de afirmar la superioridad definitiva del modelo en datos no utilizados para seleccionarlo.

Enlaces

https://github.com/acardozo96/Proyecto-Integrador-Data-Science-UTN

Codigo de Python en Colab haciendo click en el enlace de Guthub en el archivo llamado LEAME